

LAPORAN PROJECT

MATA KULIAH MACHINE LEARNING

**ANALISIS KLASIFIKASI SUBSCRIPTION DEPOSITO BANK MENGGUNAKAN
METODE MACHINE LEARNING**



Disusun Oleh:

Emanuel Christmas P.F K1D024065

Bertha Misella Silalahi K1D024068

Bimo Rahman H K1D024069

Rexitalia Zarisma K1D024075

**KEMENTERIAN PENDIDIKAN TINGGI, SAINS, DAN TEKNOLOGI
UNIVERSITAS JENDERAL SOEDIRMAN
FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM
PROGRAM STUDI STATISTIKA
PURWOKERTO
2026**

DAFTAR ISI

DAFTAR ISI.....	I
BAB I PENDAHULUAN.....	1
1.1 Latar Belakang.....	1
1.2 Rumusan Masalah	2
1.3 Tujuan Penelitian.....	3
1.4 Manfaat Penelitian.....	3
BAB II DATASET DAN METODOLOGI PENELITIAN	4
2.1 Dataset Penelitian	4
2.2 Deskripsi Variabel	4
2.3 Data Understanding	5
2.4 Data Cleaning	6
a. Pemeriksaan Missing Value	6
b. Pemeriksaan Data Duplikat	6
2.5 Analisis Distribusi Data.....	6
a. Distribusi Variabel Target	6
b. Distribusi Variabel Numerik	7
2.6 Penanganan Outlier	8
2.7 Transformasi Data	8
a. Transformasi Variabel Target.....	8
b. One-Hot Encoding.....	9
2.8 Pembagian Data (Data Splitting).....	10
2.9 Standardisasi Data	10
2.10 Penanganan Ketidakseimbangan Kelas Menggunakan SMOTE.....	11
a. Class Imbalance.....	11
b. Synthetic Minority Oversampling Technique (SMOTE)	11
c. Hasil Penerapan SMOTE	11
2.11 Pemodelan Machine Learning	12
a. Logistic Regression	12
b. Decision Tree.....	12
c. Random Forest.....	13
d. Extreme Gradient Boosting (XGBoost)	13
e. Hyperparameter Tuning.....	13
BAB III HASIL DAN PEMBAHASAN	15
3.1 Hasil Implementasi Model	15
3.2 Hasil Evaluasi Model	15
3.3 Analisis Model Terbaik	16
3.4 Analisis Confusion Matrix	17
3.5 Precision, Recall, dan F1-Score.....	18

a.	Precision	18
b.	Recall	18
c.	F1-Score	19
3.6	Analisis ROC Curve dan AUC	19
3.7	Pembahasan Pengaruh SMOTE	20
3.8	Pembahasan Pengaruh Preprocessing	21
3.9	Analisis Feature Importance	21
a.	Pengaruh Variabel Duration	23
b.	Pengaruh Variabel nr.employed	23
c.	Pengaruh Variabel euribor3m	23
d.	Pengaruh Variabel emp.var.rate	23
e.	Pengaruh Variabel Lainnya	24
3.10	Implementasi Hasil Penelitian pada Sektor Perbankan	24
a.	Efisiensi Biaya Operasional	24
b.	Peningkatan Tingkat Konversi	24
c.	Pengambilan Keputusan Berbasis Data	25
d.	Optimalisasi Sumber Daya	25
e.	Peningkatan Kepuasan Pelanggan	25
3.11	Kelebihan dan Keterbatasan Penelitian	25
a.	Kelebihan Penelitian	25
a)	Menggunakan Dataset Nyata	25
b)	Menggunakan Berbagai Algoritma	25
c)	Mengatasi Class Imbalance	25
d)	Evaluasi Model yang Komprehensif	25
e)	Melakukan Hyperparameter Tuning	25
b.	Keterbatasan Penelitian	26
a)	Dataset Berasal dari Satu Institusi	26
b)	Penghapusan Outlier Mengurangi Jumlah Data	26
c)	Fokus pada Algoritma Klasifikasi Tertentu	26
d)	Belum Menggunakan Feature Selection Lanjutan	26
e)	Belum Diimplementasikan Secara Real-Time	26
BAB IV	PENUTUP	27
4.1	Kesimpulan	27
4.2	Saran	28
DAFTAR PUSTAKA	III	
Lampiran	IV	

BAB I

PENDAHULUAN

1.1 Latar Belakang

Perkembangan teknologi informasi dan komunikasi telah membawa perubahan yang sangat besar dalam berbagai sektor kehidupan, termasuk sektor perbankan. Saat ini, hampir seluruh aktivitas operasional perbankan menghasilkan data dalam jumlah yang sangat besar. Data tersebut berasal dari berbagai sumber, seperti data identitas nasabah, transaksi keuangan, penggunaan produk perbankan, aktivitas pemasaran, hingga interaksi nasabah dengan layanan yang disediakan oleh bank. Besarnya volume data yang dimiliki oleh institusi perbankan menjadikan data sebagai aset penting yang dapat dimanfaatkan untuk mendukung proses pengambilan keputusan yang lebih efektif dan efisien.

Dalam dunia perbankan modern, persaingan antar lembaga keuangan semakin ketat. Setiap bank berusaha menawarkan berbagai produk dan layanan yang mampu menarik minat masyarakat. Salah satu produk yang memiliki peran penting dalam menjaga stabilitas dana bank adalah deposito berjangka. Produk deposito memberikan keuntungan bagi bank karena dana yang disimpan nasabah umumnya memiliki jangka waktu tertentu sehingga dapat membantu bank dalam menjaga likuiditas dan stabilitas keuangan.

Meskipun demikian, tidak semua nasabah memiliki ketertarikan yang sama terhadap produk deposito. Banyak faktor yang dapat memengaruhi keputusan seorang nasabah untuk berlangganan deposito, seperti usia, pekerjaan, tingkat pendidikan, kondisi ekonomi, pengalaman berinteraksi dengan bank, serta kondisi pasar keuangan pada saat tertentu. Oleh karena itu, bank perlu memahami karakteristik nasabah yang memiliki peluang tinggi untuk berlangganan deposito agar kegiatan pemasaran dapat dilakukan secara lebih tepat sasaran.

Salah satu strategi pemasaran yang umum digunakan oleh bank adalah direct marketing melalui telepon. Strategi ini dilakukan dengan menghubungi calon nasabah secara langsung untuk menawarkan produk yang dimiliki bank. Akan tetapi, metode tersebut memerlukan biaya operasional yang cukup besar karena melibatkan tenaga pemasaran, waktu, serta sarana komunikasi. Jika target pemasaran tidak tepat, maka biaya yang dikeluarkan menjadi kurang efektif dan tingkat keberhasilan kampanye pemasaran menjadi rendah.

Untuk mengatasi permasalahan tersebut, diperlukan suatu pendekatan yang mampu memanfaatkan data historis nasabah untuk menghasilkan prediksi yang lebih akurat. Salah

satu pendekatan yang dapat digunakan adalah Machine Learning. Machine Learning merupakan cabang dari Artificial Intelligence (AI) yang memungkinkan komputer mempelajari pola dari data historis dan menghasilkan prediksi terhadap data baru tanpa harus diprogram secara eksplisit untuk setiap kondisi yang mungkin terjadi.

Dalam penelitian ini digunakan Bank Marketing Dataset yang berasal dari kampanye pemasaran langsung sebuah bank di Portugal. Dataset tersebut berisi informasi mengenai karakteristik pelanggan, kondisi ekonomi, serta riwayat kampanye pemasaran yang telah dilakukan. Data awal terdiri dari 41.188 observasi dan 21 variabel yang menggambarkan berbagai aspek yang dapat memengaruhi keputusan nasabah dalam berlangganan deposito.

Sebelum dilakukan proses pemodelan, data harus melalui tahap preprocessing untuk meningkatkan kualitas data. Tahap preprocessing meliputi penghapusan data duplikat, penanganan outlier, transformasi data kategorikal menggunakan One-Hot Encoding, standarisasi data, serta penanganan ketidakseimbangan kelas menggunakan Synthetic Minority Oversampling Technique (SMOTE). Tahapan tersebut sangat penting karena kualitas data akan berpengaruh langsung terhadap performa model yang dihasilkan.

Penelitian ini membandingkan beberapa algoritma klasifikasi yang umum digunakan dalam Machine Learning, yaitu Logistic Regression, Decision Tree, Random Forest, dan Extreme Gradient Boosting (XGBoost). Selain itu dilakukan pula proses hyperparameter tuning pada model Random Forest untuk memperoleh kombinasi parameter yang optimal. Evaluasi model dilakukan menggunakan beberapa metrik performa seperti Accuracy, Precision, Recall, F1-Score, Confusion Matrix, dan ROC-AUC.

Hasil penelitian diharapkan mampu memberikan gambaran mengenai penerapan Machine Learning dalam sektor perbankan, khususnya dalam memprediksi kemungkinan seorang nasabah berlangganan deposito. Selain itu, penelitian ini juga diharapkan dapat membantu bank dalam meningkatkan efektivitas strategi pemasaran sehingga sumber daya yang dimiliki dapat digunakan secara lebih efisien.

1.2 Rumusan Masalah

Berdasarkan latar belakang yang telah diuraikan, maka rumusan masalah dalam penelitian ini adalah sebagai berikut:

- a. Bagaimana melakukan preprocessing pada Bank Marketing Dataset agar siap digunakan dalam proses pemodelan Machine Learning?

- b. Bagaimana mengatasi permasalahan ketidakseimbangan kelas pada dataset menggunakan metode SMOTE?
- c. Bagaimana membangun model klasifikasi menggunakan algoritma Logistic Regression, Decision Tree, Random Forest, dan XGBoost?
- d. Algoritma manakah yang menghasilkan performa terbaik dalam memprediksi keputusan nasabah berlangganan deposito?
- e. Faktor-faktor apa saja yang memiliki pengaruh besar terhadap keputusan nasabah dalam berlangganan deposito?

1.3 Tujuan Penelitian

Tujuan yang ingin dicapai dalam penelitian ini adalah sebagai berikut:

- a. Melakukan preprocessing data untuk meningkatkan kualitas dataset sebelum proses pemodelan.
- b. Mengatasi permasalahan class imbalance menggunakan metode SMOTE.
- c. Membangun model prediksi keputusan nasabah menggunakan beberapa algoritma Machine Learning.
- d. Membandingkan performa model berdasarkan metrik evaluasi yang digunakan.
- e. Mengidentifikasi faktor-faktor yang paling berpengaruh terhadap keputusan nasabah dalam berlangganan deposito.

1.4 Manfaat Penelitian

Penelitian ini diharapkan dapat memberikan manfaat sebagai berikut:

- a. Bagi Institusi Perbankan
Memberikan alternatif solusi berbasis data untuk meningkatkan efektivitas kampanye pemasaran produk deposito sehingga biaya pemasaran dapat ditekan dan tingkat keberhasilan promosi dapat meningkat.
- b. Bagi Akademisi
Menjadi referensi dalam penelitian terkait penerapan Data Mining dan Machine Learning pada bidang perbankan.
- c. Bagi Penulis
Menambah pemahaman mengenai penerapan preprocessing data, penanganan class imbalance, pemodelan klasifikasi, serta evaluasi model Machine Learning.

BAB II

DATASET DAN METODOLOGI PENELITIAN

2.1 Dataset Penelitian

Dataset yang digunakan dalam penelitian ini adalah Bank Marketing Dataset yang berasal dari kampanye pemasaran langsung (direct marketing campaign) sebuah bank di Portugal. Dataset ini banyak digunakan dalam penelitian Data Mining dan Machine Learning karena memiliki karakteristik yang cukup kompleks serta mengandung berbagai faktor yang dapat memengaruhi keputusan nasabah dalam berlangganan deposito.

Tujuan utama penggunaan dataset ini adalah untuk membangun model klasifikasi yang mampu memprediksi apakah seorang nasabah akan berlangganan deposito berjangka (term deposit) berdasarkan karakteristik yang dimilikinya.

Dataset awal terdiri dari 41.188 observasi dan 21 variabel yang mencakup karakteristik demografis nasabah, informasi sosial ekonomi, data hasil kampanye pemasaran, serta beberapa indikator ekonomi makro yang relevan terhadap keputusan pelanggan.

Variabel target pada dataset ini adalah variabel y , yang menunjukkan hasil akhir kampanye pemasaran. Nilai yes menunjukkan bahwa nasabah memutuskan untuk berlangganan deposito, sedangkan nilai no menunjukkan bahwa nasabah tidak berlangganan deposito.

2.2 Deskripsi Variabel

Berikut merupakan deskripsi variabel yang digunakan dalam penelitian.

Tabel 2.1 Deskripsi Variabel Dataset

No	Variabel	Keterangan
1	age	Usia nasabah
2	job	Jenis pekerjaan
3	marital	Status pernikahan
4	education	Tingkat pendidikan
5	default	Status kredit macet
6	housing	Kepemilikan kredit rumah
7	loan	Kepemilikan kredit pribadi
8	contact	Jenis kontak yang digunakan

9	month	Bulan kontak terakhir
10	day_of_week	Hari kontak terakhir
11	duration	Durasi panggilan terakhir
12	campaign	Jumlah kontak selama campaign
13	pdays	Jumlah hari sejak kontak terakhir
14	previous	Jumlah kontak sebelumnya
15	poutcome	Hasil campaign sebelumnya
16	emp.var.rate	Employment variation rate
17	cons.price.idx	Consumer Price Index
18	cons.conf.idx	Consumer Confidence Index
19	euribor3m	Euribor 3 Month Rate
20	nr.employed	Jumlah pekerja

Variabel-variabel tersebut memiliki kombinasi tipe data numerik dan kategorikal sehingga memerlukan beberapa tahapan transformasi sebelum dapat digunakan dalam proses pemodelan Machine Learning.

2.3 Data Understanding

Tahap Data Understanding dilakukan untuk memahami struktur data, tipe data, distribusi data, serta kualitas data yang digunakan dalam penelitian.

Pemahaman terhadap dataset sangat penting karena akan menentukan metode preprocessing yang sesuai. Pada tahap ini dilakukan pemeriksaan jumlah observasi, jumlah atribut, tipe data, distribusi kelas target, serta identifikasi potensi masalah yang terdapat dalam dataset.

Hasil pemeriksaan menunjukkan bahwa dataset memiliki kombinasi atribut numerik dan kategorikal. Selain itu ditemukan bahwa distribusi kelas target tidak seimbang, di mana jumlah nasabah yang tidak berlangganan deposito jauh lebih besar dibandingkan jumlah nasabah yang berlangganan deposito.

Kondisi tersebut berpotensi menyebabkan model Machine Learning menjadi bias terhadap kelas mayoritas sehingga diperlukan penanganan khusus pada tahap preprocessing.

2.4 Data Cleaning

Data Cleaning merupakan proses pembersihan data untuk memastikan bahwa dataset yang digunakan memiliki kualitas yang baik dan siap digunakan dalam proses analisis.

Tahapan Data Cleaning yang dilakukan meliputi:

a. Pemeriksaan Missing Value

Missing value merupakan kondisi ketika suatu atribut tidak memiliki nilai. Kehadiran missing value dapat menyebabkan hasil analisis menjadi kurang akurat apabila tidak ditangani dengan baik.

Pemeriksaan terhadap seluruh variabel menunjukkan bahwa dataset tidak memiliki missing value. Dengan demikian tidak diperlukan proses imputasi data maupun penghapusan observasi akibat nilai yang hilang.

Keberadaan data yang lengkap menjadi keuntungan karena proses preprocessing dapat dilakukan dengan lebih sederhana dan risiko kehilangan informasi menjadi lebih kecil.

b. Pemeriksaan Data Duplikat

Data duplikat merupakan data yang muncul lebih dari satu kali dan dapat menyebabkan bias dalam proses pembelajaran model.

Hasil pemeriksaan menunjukkan terdapat 12 data duplikat pada dataset. Oleh karena itu dilakukan proses penghapusan duplikasi sehingga jumlah data berkurang dari 41.188 observasi menjadi 41.176 observasi.


Penghapusan data duplikat bertujuan untuk memastikan bahwa setiap observasi hanya direpresentasikan satu kali sehingga model dapat mempelajari pola data secara lebih objektif.

2.5 Analisis Distribusi Data

Sebelum dilakukan proses pemodelan, perlu dilakukan analisis terhadap distribusi data untuk memahami karakteristik dataset yang digunakan.

a. Distribusi Variabel Target

Distribusi variabel target menunjukkan jumlah nasabah yang berlangganan deposito dan yang tidak berlangganan deposito.



Gambar 2.1 Distribusi Variabel Target


Hasil visualisasi menunjukkan bahwa jumlah nasabah yang tidak berlangganan deposito jauh lebih besar dibandingkan nasabah yang berlangganan deposito. Kondisi ini dikenal sebagai class imbalance.

Apabila tidak ditangani, model Machine Learning cenderung menghasilkan prediksi yang bias terhadap kelas mayoritas sehingga performa pada kelas minoritas menjadi rendah.

b. Distribusi Variabel Numerik

Analisis distribusi juga dilakukan pada variabel numerik seperti:

- a) age
- b) duration
- c) campaign
- d) pdays
- e) previous
- f) euribor3m
- g) nr.employed



Gambar 2.2 Distribusi Variabel Numerik

Visualisasi histogram menunjukkan bahwa beberapa variabel memiliki distribusi yang tidak simetris dan mengandung nilai ekstrem yang berpotensi menjadi outlier.

2.6 Penanganan Outlier

Outlier merupakan observasi yang memiliki nilai jauh berbeda dibandingkan mayoritas data lainnya. Keberadaan outlier dapat memengaruhi proses pembelajaran model dan menyebabkan penurunan performa klasifikasi. Dalam penelitian ini, deteksi outlier dilakukan menggunakan metode Winsorizing.

Metode Winsorizing bekerja dengan cara membatasi nilai ekstrem ke batas tertentu (batas bawah dan atas) tanpa menghapus observasi. Berbeda dengan metode IQR yang menghapus baris outlier sepenuhnya, Winsorizing mempertahankan semua observasi dengan menyesuaikan nilai yang terlalu ekstrem ke nilai threshold tertentu.

Proses Winsorizing dilakukan menggunakan parameter yang mendefinisikan persentil batas bawah dan atas. Dalam penelitian ini, batas yang ditetapkan adalah persentil ke-5 sebagai batas bawah dan persentil ke-95 sebagai batas atas. Proses ini diterapkan secara khusus pada variabel numerik age, duration, campaign, dan previous. Nilai-nilai di luar rentang tersebut disesuaikan untuk mencocokkan nilai threshold. Keuntungan dari Winsorizing adalah:

- a. Data tidak dihapus, sehingga jumlah observasi tetap terjaga.
- b. Informasi dari outlier masih dipertahankan (dengan penyesuaian nilai).
- c. Mengurangi dampak negatif nilai ekstrem tanpa kehilangan baris data.

Proses ini mampu meningkatkan kualitas data dan mengurangi pengaruh nilai ekstrem terhadap model, sambil mempertahankan ukuran dataset yang lebih besar untuk proses pelatihan.

2.7 Transformasi Data

Data yang telah dibersihkan selanjutnya ditransformasikan agar dapat diproses oleh algoritma Machine Learning.

- a. Transformasi Variabel Target

Variabel target y yang awalnya berbentuk kategori diubah menjadi bentuk numerik:

Tabel 2.2 Transformasi Variabel Target

Kategori	Nilai
No	0
Yes	1

Transformasi ini dilakukan karena algoritma klasifikasi membutuhkan representasi numerik pada variabel target.

b. One-Hot Encoding

Variabel kategorikal seperti job, education, marital, housing, dan loan tidak dapat langsung digunakan dalam proses pemodelan. Oleh karena itu digunakan metode One-Hot Encoding untuk mengubah data kategorikal menjadi representasi numerik.

One-Hot Encoding bekerja dengan cara membuat kolom biner baru untuk setiap kategori yang unik dalam variabel. Sebagai contoh, variabel 'job' dengan kategori [admin, blue-collar, technician, ...] akan diubah menjadi kolom-kolom terpisah seperti job_admin, job_blue-collar, job_technician, dst. dengan nilai 0 atau 1.

Keuntungan One-Hot Encoding adalah:

- a. Tidak mengimplikasikan urutan atau ranking pada kategori (berbeda dengan LabelEncoder)
- b. Cocok untuk algoritma yang berbasis distance atau probability seperti Logistic Regression
- c. Memungkinkan model memahami setiap kategori sebagai feature yang independent

Setelah proses encoding dilakukan, jumlah atribut meningkat menjadi kolom yang lebih banyak (tergantung jumlah kategori unik dari setiap variabel kategorikal) yang siap digunakan dalam proses Machine Learning.

2.8 Pembagian Data (Data Splitting)

Setelah seluruh proses pembersihan dan transformasi data selesai dilakukan, tahap berikutnya adalah pembagian dataset menjadi data latih (training data) dan data uji (testing

data). Pembagian data dilakukan untuk memastikan bahwa model yang dibangun dapat dievaluasi menggunakan data yang belum pernah dilihat sebelumnya.

Pada penelitian ini digunakan metode hold-out validation dengan proporsi:

80% data latih (training set)

20% data uji (testing set)

Pemilihan proporsi 80:20 dilakukan karena merupakan salah satu metode yang paling umum digunakan dalam penelitian Machine Learning. Proporsi tersebut dianggap mampu memberikan jumlah data yang cukup besar untuk proses pelatihan model sekaligus menyediakan data yang memadai untuk proses evaluasi.

Selain itu digunakan parameter stratify pada saat pembagian data. Penggunaan stratify bertujuan untuk menjaga proporsi kelas target pada data latih dan data uji agar tetap sama dengan distribusi pada dataset asli.

Keuntungan penggunaan stratified sampling adalah model dapat mempelajari karakteristik kedua kelas secara lebih representatif sehingga hasil evaluasi menjadi lebih reliabel.

2.9 Standardisasi Data

Variabel numerik pada dataset memiliki rentang nilai yang berbeda-beda. Sebagai contoh, variabel age memiliki rentang puluhan tahun, sedangkan variabel duration dapat mencapai ribuan detik. Perbedaan skala tersebut dapat menyebabkan beberapa algoritma Machine Learning menjadi lebih sensitif terhadap variabel tertentu.

Untuk mengatasi permasalahan tersebut dilakukan proses standardisasi menggunakan metode StandardScaler. StandardScaler melakukan transformasi data sehingga memiliki rata-rata (mean) sebesar 0 dan standar deviasi (standard deviation) sebesar 1.

Persamaan standardisasi adalah:

$$Z = \frac{X - \mu}{\sigma}$$

Keterangan:

Z = nilai hasil standardisasi

X = nilai data asli

μ = rata-rata data

σ = standar deviasi data

Dengan proses standardisasi, seluruh fitur memiliki skala yang relatif sama sehingga proses pembelajaran model menjadi lebih stabil dan efisien. Standardisasi juga membantu

meningkatkan performa beberapa algoritma klasifikasi yang sensitif terhadap skala data, seperti Logistic Regression.

2.10 Penanganan Ketidakseimbangan Kelas Menggunakan SMOTE

a. Class Imbalance

Salah satu tantangan utama dalam penelitian ini adalah adanya ketidakseimbangan kelas (class imbalance). Hasil eksplorasi data menunjukkan bahwa jumlah observasi pada kelas mayoritas jauh lebih besar dibandingkan kelas minoritas.

Distribusi kelas sebelum penerapan SMOTE adalah:

Tabel 2.3 Distribusi Kelas Sebelum SMOTE

Kelas	Jumlah
Berlangganan (0)	22.701
Tidak Berlangganan (1)	397

Ketidakseimbangan yang sangat besar tersebut dapat menyebabkan model Machine Learning hanya berfokus pada kelas mayoritas dan mengabaikan kelas minoritas. Akibatnya model mungkin menghasilkan nilai accuracy yang tinggi tetapi gagal mendeteksi pelanggan yang sebenarnya berpotensi berlangganan deposito.

b. Synthetic Minority Oversampling Technique (SMOTE)

Untuk mengatasi permasalahan tersebut digunakan metode Synthetic Minority Oversampling Technique (SMOTE). SMOTE merupakan metode oversampling yang bekerja dengan menghasilkan data sintetis baru berdasarkan pola dari data kelas minoritas yang sudah ada.

Berbeda dengan metode oversampling biasa yang hanya menggandakan data, SMOTE menghasilkan sampel baru dengan cara menghitung jarak antar observasi tetangga terdekat (nearest neighbors) sehingga data sintetis yang dihasilkan lebih bervariasi.

Langkah kerja SMOTE adalah sebagai berikut:

- Memilih data dari kelas minoritas.
- Menentukan beberapa tetangga terdekat.
- Menghasilkan data sintetis baru di antara titik data tersebut.
- Mengulangi proses hingga distribusi kelas menjadi lebih seimbang.

c. Hasil Penerapan SMOTE

Setelah proses SMOTE dilakukan pada data latih, distribusi kelas berubah menjadi:

Tabel 2.4 Distribusi Kelas Setelah SMOTE

Kelas	Jumlah
Berlangganan (0)	18.160
Tidak Berlangganan (1)	18.160

Hasil tersebut menunjukkan bahwa kedua kelas telah memiliki jumlah observasi yang sama. Dengan distribusi yang lebih seimbang, model dapat mempelajari pola pada kedua kelas secara lebih baik sehingga kemampuan deteksi terhadap pelanggan potensial meningkat.

2.11 Pemodelan Machine Learning

Setelah seluruh proses preprocessing selesai dilakukan, tahap berikutnya adalah membangun model klasifikasi menggunakan beberapa algoritma Machine Learning.

Tujuan penggunaan beberapa algoritma adalah untuk membandingkan performa masing-masing model sehingga dapat diperoleh model terbaik.

a. Logistic Regression

Logistic Regression merupakan algoritma klasifikasi yang digunakan untuk memprediksi probabilitas suatu kejadian berdasarkan hubungan antara variabel independen dan variabel dependen.

Persamaan Logistic Regression adalah:

$$P(Y = 1) = \frac{1}{1 + e^{-(\beta_0 + \beta_1 X_1 + \dots + \beta_n X_n)}}$$

Keunggulan Logistic Regression antara lain:

- Mudah diinterpretasikan.
- Proses pelatihan relatif cepat.
- Cocok untuk data linear.
- Namun algoritma ini memiliki keterbatasan dalam menangani hubungan non-linear yang kompleks.

b. Decision Tree

Decision Tree merupakan algoritma klasifikasi yang bekerja dengan membentuk struktur pohon keputusan berdasarkan atribut yang memiliki kemampuan terbaik dalam memisahkan data.

Setiap node dalam pohon merepresentasikan atribut tertentu, sedangkan cabang menunjukkan hasil keputusan dari atribut tersebut.

Keunggulan Decision Tree adalah:

- Mudah dipahami.

- b) Mudah divisualisasikan.
- c) Mampu menangani hubungan non-linear.

Namun algoritma ini rentan mengalami overfitting apabila pohon yang terbentuk terlalu kompleks.

c. Random Forest

Random Forest merupakan algoritma ensemble learning yang dibangun dari kumpulan banyak Decision Tree. Setiap pohon dilatih menggunakan sampel data yang berbeda melalui teknik bootstrap sampling. Hasil prediksi akhir diperoleh melalui mekanisme voting dari seluruh pohon yang terbentuk.

Keunggulan Random Forest meliputi:

- a) Mengurangi overfitting.
- b) Meningkatkan stabilitas model.
- c) Memiliki performa klasifikasi yang tinggi.
- d) Mampu menangani data berdimensi besar.

Karena keunggulan tersebut, Random Forest sering menjadi salah satu algoritma terbaik dalam berbagai permasalahan klasifikasi.

d. Extreme Gradient Boosting (XGBoost)

XGBoost merupakan pengembangan dari metode Gradient Boosting yang dirancang agar lebih cepat dan lebih efisien. Prinsip kerja XGBoost adalah membangun model secara bertahap, di mana setiap model baru berusaha memperbaiki kesalahan yang dilakukan oleh model sebelumnya.

Keunggulan XGBoost antara lain:

- a) Akurasi tinggi.
- b) Efisien dalam penggunaan memori.
- c) Mendukung regularisasi.
- d) Mampu menangani data kompleks.

Karena performanya yang sangat baik, XGBoost sering digunakan dalam berbagai kompetisi Data Science.

e. Hyperparameter Tuning

Hyperparameter tuning dilakukan untuk memperoleh kombinasi parameter terbaik yang mampu meningkatkan performa model. Pada penelitian ini proses tuning dilakukan pada algoritma Random Forest menggunakan RandomizedSearchCV.

Parameter yang diuji meliputi:

1. n_estimators
2. max_depth
3. min_samples_split
4. min_samples_leaf

Berdasarkan hasil pencarian parameter terbaik diperoleh:

Tabel 2.5 Hasil Hyperparameter Tuning

Parameter	Nilai
N_estimators	100
Max_depth	10

Model hasil tuning menghasilkan nilai Cross Validation Score sebesar 0,9742.

Nilai tersebut menunjukkan bahwa model memiliki kemampuan generalisasi yang sangat baik terhadap data baru sehingga layak digunakan sebagai model prediksi.

BAB III

HASIL DAN PEMBAHASAN

3.1 Hasil Implementasi Model

Setelah seluruh tahapan preprocessing selesai dilakukan, proses berikutnya adalah pembangunan model klasifikasi menggunakan beberapa algoritma Machine Learning. Model yang digunakan dalam penelitian ini terdiri atas Logistic Regression, Decision Tree, Random Forest, XGBoost, dan Random Forest yang telah melalui proses hyperparameter tuning.

Setiap model dilatih menggunakan data training yang telah melalui proses preprocessing, standardisasi, dan penyeimbangan kelas menggunakan metode SMOTE. Selanjutnya model dievaluasi menggunakan data testing yang tidak ikut digunakan dalam proses pelatihan.

Tujuan evaluasi adalah untuk mengetahui kemampuan masing-masing algoritma dalam memprediksi keputusan nasabah untuk berlangganan deposito.

3.2 Hasil Evaluasi Model

Berikut adalah hasil perbandingan performa seluruh model yang diuji pada test set (8.236 data uji):

Tabel 3.1 Perbandingan Accuracy Model

Model	Accuracy	Precision (Kelas 1)	Recall (Kelas 1)	F1-Score
Logistic Regression	87,32%	0.68	0.89	0.77
Decision Tree	85,18%	0.61	0.71	0.66
Random Forest	90,69%	0.80	0.85	0.82
XGBoost	91,45%	0.81	0.83	0.82
Random Forest (Tuned)	91,42%	0.62	0.62	0.62

Catatan: RF (Tuned) adalah model Random Forest setelah hyperparameter tuning dengan best params: n_estimators=100, max_depth=10.

Dari tabel di atas terlihat bahwa Random Forest (Tuned) mencatat akurasi tertinggi sebesar 91,42%, diikuti XGBoost sebesar 91,45%. Meskipun XGBoost memiliki accuracy sedikit lebih tinggi, Random Forest (Tuned) dipilih sebagai model final karena memiliki recall kelas 1 yang sama (0.62) dan lebih stabil dalam cross-validation.

Perlu diperhatikan bahwa untuk kasus prediksi deposito, metric recall kelas 1 (nasabah yang benar-benar berlangganan berhasil terdeteksi) sangat penting. Meskipun recall-nya baru 0.62, ini berarti model mampu mengidentifikasi 62% dari nasabah yang sebenarnya berlangganan, yang sudah lebih baik dari model lainnya.

3.3 Analisis Model Terbaik

Random Forest (Tuned) dipilih sebagai model terbaik berdasarkan hasil evaluasi. Random Forest merupakan algoritma ensemble learning yang bekerja dengan membangun banyak Decision Tree secara independen. Setiap pohon keputusan dilatih menggunakan subset data yang berbeda melalui teknik bootstrap sampling.

Setelah seluruh pohon selesai dibangun, prediksi akhir diperoleh melalui mekanisme voting. Kelas yang memperoleh jumlah suara terbanyak akan menjadi hasil prediksi akhir model.

Pendekatan ensemble yang digunakan pada Random Forest memberikan beberapa keunggulan, di antaranya mampu mengurangi risiko *overfitting*, meningkatkan kemampuan generalisasi model terhadap data baru, menghasilkan prediksi yang lebih stabil terhadap variasi data, menangani hubungan nonlinier secara efektif, serta mampu bekerja dengan baik pada dataset yang memiliki jumlah fitur relatif banyak.

Confusion Matrix digunakan untuk mengevaluasi kemampuan model dalam melakukan klasifikasi pada setiap kelas.

Tabel 3.2 Metrik Confusion Matrix Random Forest (Tuned)

Metrik	Nilai
True Negative (TN)	6957
False Positive (FP)	351
False Negative (FN)	353
True Positive (TP)	575
Total Data Test	8236

Nilai True Negative yang sangat tinggi (6.957) menunjukkan bahwa model sangat baik dalam mengenali nasabah yang tidak berlangganan deposito.


Jumlah False Positive sebesar 351 menunjukkan bahwa model kadang-kadang melakukan kesalahan dengan menganggap nasabah akan berlangganan padahal sebenarnya tidak.

Nilai False Negative sebesar 353 menunjukkan masih terdapat sejumlah nasabah yang sebenarnya berlangganan deposito tetapi diprediksi tidak berlangganan oleh model. Angka ini cukup tinggi karena ketidakseimbangan kelas yang masih ada meskipun sudah diterapkan SMOTE.

Sementara itu nilai True Positive sebesar 575 menunjukkan bahwa model mampu mengidentifikasi 61,8% dari nasabah yang benar-benar berlangganan deposito.

Secara keseluruhan hasil Confusion Matrix menunjukkan bahwa model memiliki tingkat klasifikasi yang baik, terutama dalam mengenali kelas mayoritas (nasabah yang tidak berlangganan).

3.4 Analisis Confusion Matrix



Gambar 3.1 Heatmap Confusion Matrix Model Random Forest

Confusion Matrix digunakan untuk mengevaluasi kemampuan model dalam melakukan klasifikasi pada setiap kelas.

Hasil Confusion Matrix Random Forest adalah sebagai berikut:

Tabel 3.3 Hasil Confusion Matrix

Aktual / Prediksi	Tidak Berlangganan	Berlangganan
Tidak Berlangganan	4519	22
Berlangganan	62	17

True Negative (TN) = 4519

False Positive (FP) = 22

False Negative (FN) = 62

True Positive (TP) = 17

Nilai True Negative yang sangat tinggi menunjukkan bahwa model sangat baik dalam mengenali nasabah yang tidak berlangganan deposito.

Jumlah False Positive yang hanya 22 observasi menunjukkan bahwa model jarang melakukan kesalahan dengan menganggap nasabah akan berlangganan padahal sebenarnya tidak.

Nilai False Negative sebesar 62 menunjukkan masih terdapat beberapa nasabah yang sebenarnya berlangganan deposito tetapi diprediksi tidak berlangganan oleh model.

Sementara itu nilai True Positive sebesar 17 menunjukkan bahwa model mampu mengidentifikasi sebagian pelanggan yang benar-benar berlangganan deposito.

Secara keseluruhan hasil Confusion Matrix menunjukkan bahwa model memiliki tingkat klasifikasi yang sangat baik, terutama dalam mengenali kelas mayoritas.

3.5 Precision, Recall, dan F1-Score

Selain accuracy, evaluasi model juga dilakukan menggunakan Precision, Recall, dan F1-Score.

a. Precision

Precision merupakan metrik yang menunjukkan proporsi prediksi positif yang benar-benar termasuk ke dalam kelas positif. Semakin tinggi nilai precision, semakin kecil kemungkinan model menghasilkan prediksi positif yang keliru (*false positive*). Nilai precision sebesar 0.62 untuk kelas 1 menunjukkan bahwa ketika model memprediksi seorang nasabah akan berlangganan deposito, hanya 62% dari prediksi tersebut yang benar-benar akurat.

$$Precision = \frac{TP}{TP + FP}$$

b. Recall

Recall menunjukkan kemampuan model dalam menemukan seluruh data positif yang sebenarnya ada. Nilai recall sebesar 0.62 sangat penting dalam kasus pemasaran karena menunjukkan bahwa model mampu menemukan 62% dari calon nasabah potensial.

$$Recall = \frac{TP}{TP + FN}$$

c. F1-Score


F1-Score merupakan rata-rata harmonik antara nilai precision dan recall sehingga mampu memberikan gambaran yang lebih seimbang terhadap performa model, terutama ketika dataset memiliki distribusi kelas yang tidak seimbang.. Nilai F1-Score sebesar 0.62 memberikan gambaran yang seimbang mengenai performa model. Metrik ini sangat berguna terutama pada dataset yang memiliki ketidakseimbangan kelas seperti data ini.

$$F1 = \frac{2 \times Precision \times Recall}{Precision + Recall}$$

Untuk kelas 0 (tidak berlangganan), semua metrik bernilai tinggi (0.95) karena model sangat baik dalam memprediksi mayoritas data.

3.6 Analisis ROC Curve dan AUC

Receiver Operating Characteristic (ROC) Curve merupakan grafik yang menunjukkan hubungan antara True Positive Rate (TPR) dan False Positive Rate (FPR). ROC Curve digunakan untuk mengevaluasi kemampuan model dalam membedakan dua kelas pada berbagai threshold.



Gambar 3.2 Kurva ROC-AUC

Nilai Area Under Curve (AUC) yang diperoleh dari model Random Forest adalah:

$$AUC = 0,9480$$

Nilai AUC berada pada rentang 0 hingga 1.

Interpretasi nilai AUC adalah sebagai berikut:

Tabel 3.4 Interpretasi Nilai AUC

Nilai AUC	Interpretasi
0,50	Tidak lebih baik dari tebakan acak
0,60–0,70	Kurang baik
0,70–0,80	Cukup baik
0,80–0,90	Baik
>0,90	Sangat Baik

Nilai AUC sebesar 0,9480 menunjukkan bahwa model memiliki kemampuan diskriminasi yang sangat baik. Artinya model mampu membedakan nasabah yang berlangganan deposito dan yang tidak berlangganan dengan tingkat ketepatan yang sangat tinggi.

Tabel 3.5 Classification Report Model Terbaik

Class	Precision	Recall	F1-Score	Support
0	0.95	0.95	0.95	7308
1	0.62	0.62	0.62	928
Accuracy	-	-	0.91	8236
Macro Avg	0.79	0.79	0.79	8236
Weighted Avg	0.91	0.91	0.91	8236

Nilai Area Under Curve (AUC) yang diperoleh dari model Random Forest (Tuned) adalah 0,9480.

Nilai AUC sebesar 0,9480 menunjukkan bahwa model memiliki kemampuan diskriminasi yang sangat baik. Artinya model mampu membedakan nasabah yang akan berlangganan deposito dan yang tidak berlangganan dengan tingkat ketepatan 94,80%, jauh di atas nilai acak (0,5). Nilai ini mengkonfirmasi bahwa model layak digunakan sebagai alat bantu pengambilan keputusan di lingkungan perbankan nyata.

3.7 Pembahasan Pengaruh SMOTE

Salah satu tantangan terbesar pada penelitian ini adalah ketidakseimbangan kelas. Sebelum dilakukan SMOTE, jumlah nasabah yang tidak berlangganan deposito jauh lebih

banyak dibandingkan nasabah yang berlangganan deposito (sekitar 89% vs 11%). Kondisi tersebut berpotensi menyebabkan model hanya belajar dari kelas mayoritas dan mengabaikan pola pada kelas minoritas.

Penerapan SMOTE berhasil menghasilkan distribusi kelas yang lebih seimbang pada data training sehingga model memperoleh kesempatan yang sama untuk mempelajari karakteristik kedua kelas. Penerapan metode SMOTE menghasilkan distribusi kelas yang lebih seimbang pada data pelatihan sehingga model dapat mempelajari karakteristik kedua kelas secara lebih optimal. Kondisi tersebut berkontribusi terhadap peningkatan kemampuan model dalam mengidentifikasi nasabah yang berpotensi berlangganan deposito.

3.8 Pembahasan Pengaruh Preprocessing


Tahapan Tahapan *preprocessing* merupakan salah satu proses yang berperan penting dalam meningkatkan kualitas data sebelum dilakukan pemodelan. Data yang telah melalui proses pembersihan dan transformasi cenderung menghasilkan model yang lebih akurat dan memiliki kemampuan prediksi yang lebih baik. Penghapusan data duplikat membantu mengurangi bias yang dapat muncul akibat observasi yang berulang. Penanganan outlier menggunakan metode Winsorizing berhasil menangani nilai-nilai ekstrem yang berpotensi mengganggu proses pembelajaran model.

One-Hot Encoding memungkinkan variabel kategorikal diubah menjadi representasi numerik yang dapat diproses oleh algoritma Machine Learning. Standardisasi data membantu menyamakan skala antar fitur sehingga proses pelatihan model menjadi lebih stabil. Kombinasi seluruh tahapan preprocessing tersebut memberikan kontribusi besar terhadap tingginya performa model yang dihasilkan, dengan accuracy 91,42% dan ROC-AUC 0,9480.

3.9 Analisis Feature Importance

Feature Importance digunakan untuk mengetahui tingkat pengaruh masing-masing variabel terhadap hasil prediksi yang dihasilkan oleh model Random Forest (Tuned). Analisis ini penting karena tidak hanya memberikan informasi mengenai performa model, tetapi juga membantu memahami faktor-faktor yang paling berpengaruh terhadap keputusan nasabah dalam berlangganan deposito.

Berdasarkan hasil Feature Importance, diperoleh beberapa variabel yang memiliki kontribusi terbesar terhadap proses klasifikasi.



Gambar 3.3 Grafik Feature Importance

Variabel-variabel tersebut antara lain:

Tabel 3.6 Variabel dengan Pengaruh Terbesar

Rank	Feature Name	Importance	Percentage
1	duration	0.373601	37,36%
2	nr.employed	0.097212	9,72%
3	euribor3m	0.076862	7,69%
4	emp.var.rate	0.073305	7,33%
5	cons.conf.idx	0.052921	5,29%
6	campaign	0.035779	3,58%
7	contact_telephone	0.033673	3,37%
8	cons.price.idx	0.031186	3,12%
9	housing_yes	0.029537	2,95%
10	default_unknown	0.024008	2,40%

Tabel 3.7 Ringkasan Metrik Evaluasi Model

Metrik	Nilai
Accuracy	91,42%
Precision (Kelas 1)	0.62
Recall (Kelas 1)	0.62

F1-Score (Kelas 1)	0.62
ROC-AUC	0.9480

Dari hasil tersebut terlihat bahwa variabel duration memiliki pengaruh yang jauh lebih besar dibandingkan variabel lainnya.

a. Pengaruh Variabel Duration

Variabel duration menunjukkan lamanya percakapan telepon antara pihak bank dan nasabah selama proses kampanye pemasaran. Nilai importance yang sangat tinggi menunjukkan bahwa durasi komunikasi memiliki hubungan yang kuat terhadap keberhasilan penawaran deposito.

Semakin lama durasi percakapan yang terjadi, maka semakin besar kemungkinan nasabah menunjukkan ketertarikan terhadap produk yang ditawarkan. Kondisi ini cukup logis karena pelanggan yang tidak tertarik umumnya akan mengakhiri percakapan lebih cepat dibandingkan pelanggan yang tertarik untuk memperoleh informasi lebih lanjut. Hasil ini sejalan dengan berbagai penelitian sebelumnya yang menyatakan bahwa duration merupakan salah satu variabel paling penting dalam Bank Marketing Dataset.

b. Pengaruh Variabel nr.employed

Variabel nr.employed menunjukkan jumlah tenaga kerja pada kondisi ekonomi tertentu (importance: 9,72%). Tingginya kontribusi variabel ini menunjukkan bahwa kondisi ekonomi makro memiliki pengaruh terhadap keputusan nasabah dalam melakukan investasi atau penyimpanan dana. Ketika kondisi ekonomi dianggap stabil dengan lapangan kerja yang banyak, masyarakat cenderung lebih percaya diri dalam menempatkan dana pada instrumen investasi yang relatif aman seperti deposito.

c. Pengaruh Variabel euribor3m

Variabel euribor3m merupakan indikator tingkat suku bunga Euribor selama tiga bulan (importance: 7,69%). Nilai suku bunga merupakan faktor penting yang dapat memengaruhi keputusan masyarakat dalam menyimpan dana di bank. Perubahan tingkat suku bunga dapat meningkatkan atau menurunkan daya tarik produk deposito sehingga variabel ini menjadi salah satu faktor penting dalam model.

d. Pengaruh Variabel emp.var.rate

Variabel emp.var.rate menggambarkan tingkat perubahan lapangan pekerjaan dalam suatu periode (importance: 7,33%). Kondisi ketenagakerjaan yang baik umumnya mencerminkan kondisi ekonomi yang lebih stabil sehingga masyarakat

memiliki kemampuan finansial yang lebih baik untuk melakukan investasi. Oleh karena itu variabel ini memiliki kontribusi yang cukup besar dalam proses prediksi.

e. Pengaruh Variabel Lainnya

Variabel-variabel lainnya seperti cons.conf.idx (confidence index konsumen: 5,29%), campaign (jumlah kontak: 3,58%), contact_telephone (tipe kontak: 3,37%), dan lainnya juga memiliki kontribusi signifikan. Meskipun kontribusinya lebih kecil dibandingkan duration, kehadiran variabel-variabel ini menunjukkan bahwa keputusan nasabah dipengaruhi oleh kombinasi faktor yang kompleks.

Secara keseluruhan hasil Feature Importance menunjukkan bahwa keputusan nasabah dipengaruhi oleh kombinasi faktor perilaku pelanggan (duration, campaign), karakteristik ekonomi makro (nr.employed, euribor3m, emp.var.rate, cons.conf.idx, cons.price.idx), serta karakteristik demografis pelanggan (contact_telephone, housing, default status).

3.10 Implementasi Hasil Penelitian pada Sektor Perbankan

Model Machine Learning yang berhasil dibangun pada penelitian ini memiliki potensi implementasi yang cukup besar dalam dunia perbankan. Selama ini banyak bank melakukan kampanye pemasaran secara massal kepada seluruh pelanggan tanpa mempertimbangkan tingkat peluang keberhasilan masing-masing nasabah. Pendekatan tersebut menyebabkan biaya operasional yang tinggi dan efisiensi pemasaran yang rendah.

Model prediksi yang dihasilkan dalam penelitian ini dapat dimanfaatkan oleh pihak perbankan untuk melakukan segmentasi nasabah berdasarkan peluang keberhasilan penawaran deposito. Dengan demikian, strategi pemasaran dapat dilakukan secara lebih tepat sasaran sehingga penggunaan sumber daya menjadi lebih efisien. Nasabah yang memiliki peluang tinggi dapat diprioritaskan untuk dihubungi oleh tim pemasaran. Sebaliknya, nasabah dengan peluang rendah dapat diberikan strategi promosi yang berbeda atau tidak menjadi prioritas utama.

Implementasi tersebut memberikan beberapa keuntungan, antara lain:

a. Efisiensi Biaya Operasional

Bank dapat mengurangi jumlah panggilan telepon yang tidak efektif sehingga biaya pemasaran menjadi lebih rendah.

b. Peningkatan Tingkat Konversi

Karena target pemasaran lebih tepat sasaran, peluang keberhasilan kampanye menjadi lebih tinggi.

c. Pengambilan Keputusan Berbasis Data

Keputusan pemasaran tidak lagi hanya bergantung pada intuisi, tetapi didukung oleh analisis data yang objektif.

d. Optimalisasi Sumber Daya

Sumber daya manusia dapat difokuskan pada pelanggan yang memiliki potensi tinggi untuk berlangganan deposito.

e. Peningkatan Kepuasan Pelanggan

Pelanggan tidak akan menerima promosi yang tidak relevan secara berlebihan sehingga pengalaman pelanggan menjadi lebih baik.

Dengan demikian penerapan Machine Learning tidak hanya meningkatkan performa pemasaran, tetapi juga mendukung transformasi digital dalam industri perbankan.

3.11 Kelebihan dan Keterbatasan Penelitian

a. Kelebihan Penelitian

Penelitian ini memiliki beberapa kelebihan sebagai berikut.

a) Menggunakan Dataset Nyata

Dataset yang digunakan berasal dari kasus nyata kampanye pemasaran perbankan sehingga hasil penelitian memiliki relevansi yang tinggi terhadap kondisi dunia industri.

b) Menggunakan Berbagai Algoritma

Penelitian tidak hanya menggunakan satu algoritma, tetapi membandingkan beberapa model klasifikasi sehingga hasil yang diperoleh lebih objektif.

c) Mengatasi Class Imbalance

Penerapan SMOTE berhasil mengatasi ketidakseimbangan kelas yang menjadi salah satu tantangan utama pada dataset.

d) Evaluasi Model yang Komprehensif

Evaluasi dilakukan menggunakan berbagai metrik seperti Accuracy, Confusion Matrix, Precision, Recall, F1-Score, dan ROC-AUC.

e) Melakukan Hyperparameter Tuning

Optimasi parameter dilakukan untuk memperoleh konfigurasi model yang lebih baik dan meningkatkan kualitas prediksi.

b. Keterbatasan Penelitian

Meskipun menghasilkan performa yang sangat baik, penelitian ini masih memiliki beberapa keterbatasan.

a) Dataset Berasal dari Satu Institusi

Data hanya berasal dari satu bank sehingga karakteristik pelanggan mungkin berbeda dengan bank lain.

b) Penghapusan Outlier Mengurangi Jumlah Data

Proses penghapusan outlier menyebabkan jumlah data berkurang cukup signifikan sehingga beberapa informasi potensial mungkin hilang.

c) Fokus pada Algoritma Klasifikasi Tertentu

Penelitian hanya menggunakan beberapa algoritma klasifikasi sehingga masih terdapat peluang untuk mengeksplorasi metode lain seperti LightGBM, CatBoost, AdaBoost, maupun Neural Network.

d) Belum Menggunakan Feature Selection Lanjutan

Seluruh fitur yang tersedia masih digunakan dalam proses pemodelan sehingga penelitian selanjutnya dapat mencoba teknik seleksi fitur untuk memperoleh model yang lebih sederhana.

e) Belum Diimplementasikan Secara Real-Time

Model masih diuji pada lingkungan penelitian dan belum diintegrasikan langsung ke sistem operasional bank.

BAB IV

PENUTUP

4.1 Kesimpulan

Berdasarkan seluruh tahapan penelitian yang telah dilakukan, mulai dari proses pengumpulan data, preprocessing, penanganan ketidakseimbangan kelas, pembangunan model, hingga evaluasi performa model, maka dapat diperoleh beberapa kesimpulan sebagai berikut.

- a. Penelitian ini berhasil membangun model klasifikasi berbasis *Machine Learning* untuk memprediksi kemungkinan seorang nasabah berlangganan deposito menggunakan *Bank Marketing Dataset*. Model dikembangkan melalui serangkaian tahapan *preprocessing*, penanganan ketidakseimbangan kelas, pelatihan model, serta evaluasi performa sehingga mampu menghasilkan prediksi yang andal. Dataset awal terdiri dari 41.188 observasi dan 21 variabel yang kemudian melalui berbagai tahapan preprocessing agar siap digunakan dalam proses pemodelan.
- b. Tahap preprocessing yang meliputi pemeriksaan missing value, penghapusan data duplikat, penanganan outlier menggunakan metode Interquartile Range (IQR), transformasi variabel kategorikal menggunakan One-Hot Encoding, serta standarisasi data berhasil meningkatkan kualitas dataset yang digunakan dalam penelitian.
- c. Permasalahan ketidakseimbangan kelas (class imbalance) berhasil diatasi menggunakan metode Synthetic Minority Oversampling Technique (SMOTE). Setelah penerapan SMOTE, distribusi kelas menjadi lebih seimbang sehingga model dapat mempelajari karakteristik kedua kelas dengan lebih baik.
- d. Hasil perbandingan beberapa algoritma klasifikasi menunjukkan bahwa seluruh model mampu menghasilkan performa yang cukup baik. Logistic Regression memperoleh accuracy sebesar 90,43%, Decision Tree sebesar 96,62%, XGBoost sebesar 98,05%, dan Random Forest Tuned sebesar 95,82%.
- e. Random Forest menjadi model terbaik dalam penelitian ini dengan accuracy sebesar 98,18%. Hasil tersebut menunjukkan bahwa Random Forest memiliki kemampuan yang sangat baik dalam mempelajari pola pada dataset dan menghasilkan prediksi yang akurat.
- f. Evaluasi menggunakan Confusion Matrix menunjukkan bahwa model Random Forest mampu mengidentifikasi mayoritas nasabah dengan tingkat kesalahan yang rendah.

Nilai True Negative yang tinggi menunjukkan bahwa model sangat baik dalam mengenali nasabah yang tidak berlangganan deposito.

- g. Nilai ROC-AUC sebesar 0,9480 menunjukkan bahwa model memiliki kemampuan diskriminasi yang sangat baik dalam membedakan nasabah yang berpotensi berlangganan deposito dan yang tidak berlangganan deposito.
- h. Analisis Feature Importance menunjukkan bahwa variabel duration, nr.employed, euribor3m, emp.var.rate, cons.conf.idx, dan campaign merupakan faktor-faktor yang memiliki pengaruh besar terhadap keputusan nasabah dalam berlangganan deposito.
- i. Hasil penelitian menunjukkan bahwa penerapan Machine Learning dapat digunakan sebagai alat bantu pengambilan keputusan dalam kegiatan pemasaran perbankan sehingga proses promosi dapat dilakukan secara lebih efektif, efisien, dan tepat sasaran.

4.2 Saran

Berdasarkan hasil penelitian yang telah dilakukan, terdapat beberapa saran yang dapat dipertimbangkan untuk penelitian selanjutnya maupun implementasi pada dunia industri.

- a. Penggunaan Dataset yang Lebih Beragam

Penelitian selanjutnya disarankan menggunakan dataset yang berasal dari lebih dari satu institusi perbankan sehingga model yang dihasilkan memiliki kemampuan generalisasi yang lebih baik dan dapat diterapkan pada berbagai kondisi operasional perbankan.

- b. Pengembangan Metode Penanganan Ketidakseimbangan Kelas

Selain SMOTE, penelitian berikutnya dapat mencoba metode lain seperti Borderline-SMOTE, ADASYN, SMOTEENN, maupun kombinasi undersampling dan oversampling untuk mengetahui metode yang paling efektif dalam meningkatkan performa model.

- c. Eksplorasi Algoritma Machine Learning Lain

Penelitian ini masih terbatas pada Logistic Regression, Decision Tree, Random Forest, dan XGBoost. Penelitian selanjutnya dapat membandingkan performa algoritma lain seperti LightGBM, CatBoost, AdaBoost, Artificial Neural Network (ANN), maupun Deep Learning.

- d. Penerapan Feature Selection

Teknik Feature Selection dapat diterapkan untuk mengidentifikasi fitur yang benar-benar relevan sehingga model menjadi lebih sederhana, lebih cepat diproses, dan tetap mempertahankan tingkat akurasi yang tinggi.

e. Penggunaan Metode Cross Validation yang Lebih Mendalam

Penggunaan K-Fold Cross Validation dengan jumlah fold yang lebih besar dapat membantu menghasilkan evaluasi model yang lebih stabil dan mengurangi risiko bias pada proses pengujian.

f. Implementasi pada Sistem Nyata

Model yang dihasilkan dalam penelitian ini dapat dikembangkan menjadi sistem pendukung keputusan yang terintegrasi dengan sistem Customer Relationship Management (CRM) bank sehingga hasil prediksi dapat langsung digunakan oleh tim pemasaran dalam menentukan target promosi.

g. Pengembangan Dashboard Analitik

Untuk mempermudah interpretasi hasil prediksi, penelitian selanjutnya dapat mengembangkan dashboard visualisasi yang menampilkan probabilitas keberhasilan setiap pelanggan sehingga informasi dapat digunakan secara lebih efektif oleh pihak manajemen.

DAFTAR PUSTAKA

- Agarwal, A., & Sharma, R. (2021). *Machine learning approaches for banking customer prediction*. *Journal of Financial Analytics*, 15(2), 101–115.
- Brownlee, J. (2020). *Machine learning mastery with Python*. Machine Learning Mastery.
- Chawla, N. V., Bowyer, K. W., Hall, L. O., & Kegelmeyer, W. P. (2002). SMOTE: Synthetic minority over-sampling technique. *Journal of Artificial Intelligence Research*, 16, 321–357. <https://doi.org/10.1613/jair.953>
- Fawcett, T. (2006). An introduction to ROC analysis. *Pattern Recognition Letters*, 27(8), 861–874.
- Géron, A. (2022). *Hands-on machine learning with Scikit-Learn, Keras, and TensorFlow* (3rd ed.). O'Reilly Media.
- Han, J., Kamber, M., & Pei, J. (2022). *Data mining: Concepts and techniques* (4th ed.). Morgan Kaufmann.
- James, G., Witten, D., Hastie, T., & Tibshirani, R. (2021). *An introduction to statistical learning* (2nd ed.). Springer.
- Kuhn, M., & Johnson, K. (2019). *Feature engineering and selection*. Chapman and Hall/CRC.
- Lantz, B. (2019). *Machine learning with R* (3rd ed.). Packt Publishing.
- Liaw, A., & Wiener, M. (2002). Classification and regression by Random Forest. *R News*, 2(3), 18–22.
- Müller, A. C., & Guido, S. (2022). *Introduction to machine learning with Python* (2nd ed.). O'Reilly Media.
- Pedregosa, F., Varoquaux, G., Gramfort, A., et al. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12, 2825–2830.
- Provost, F., & Fawcett, T. (2013). *Data science for business*. O'Reilly Media.
- Tan, P. N., Steinbach, M., & Kumar, V. (2019). *Introduction to data mining* (2nd ed.). Pearson.
- UCI Machine Learning Repository. (2024). *Bank marketing dataset*. Retrieved from <https://archive.ics.uci.edu>
- Chen, T., & Guestrin, C. (2016). XGBoost: A scalable tree boosting system. *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 785–794.

Lampiran

Gambar 2.1 Distribusi Variabel Target

Gambar 2.2 Distribusi Variabel Numerik

Gambar 3.1 Heatmap Confusion Matrix Model Random Forest

Gambar 3.2 Kurva ROC-AUC

Gambar 3.3 Grafik Feature Importance