


ANALISIS KLASIFIKASI SUBSCRIPTION DEPOSITO NASABAH BANK MENGUNAKAN METODE MACHINE LEARNING

Kelompok F



Anggota Kelompok




Emanuel Christmas P. F (K1D024068)

Bertha Misella Silalahi (K1D024068)

Bimo Rahman H (K1D024069)

Rexitalia Zarisma (K1D024075)





LATAR BELAKANG

Deposito merupakan salah satu produk perbankan yang banyak digunakan sebagai sarana investasi dan penyimpanan dana. Namun, tidak semua nasabah yang menjadi target kampanye pemasaran memiliki ketertarikan untuk berlangganan produk deposito. Oleh karena itu, diperlukan pendekatan yang dapat membantu bank mengidentifikasi calon nasabah yang berpotensi berlangganan deposito sehingga strategi pemasaran dapat dilakukan secara lebih efektif. Salah satu pendekatan yang dapat digunakan adalah machine learning untuk mengklasifikasikan keputusan nasabah berdasarkan karakteristik dan riwayat kampanye pemasaran.

Rumusan Masalah

1. Bagaimana membangun model machine learning untuk mengklasifikasikan keputusan nasabah dalam berlangganan deposito?
2. Algoritma klasifikasi manakah yang memiliki kinerja terbaik pada dataset Bank Marketing?
3. Fitur apa yang paling berpengaruh terhadap keputusan nasabah berlangganan deposito?




Tujuan

1. Membangun dan membandingkan model Logistic Regression, Decision Tree, Random Forest, dan XGBoost untuk klasifikasi nasabah.
2. Menerapkan tahapan machine learning mulai dari preprocessing, SMOTE, pemodelan, hingga evaluasi model.
3. Mengidentifikasi fitur yang paling berpengaruh terhadap keputusan nasabah berlangganan deposito.

Deskripsi Dataset

Dataset Bank Marketing merupakan dataset yang diperoleh dari Kaggle dan digunakan untuk mengklasifikasikan keputusan nasabah dalam berlangganan deposito. Dataset terdiri dari 41.188 data dan 21 variabel, yang mencakup informasi demografi nasabah, aktivitas kampanye pemasaran, serta kondisi ekonomi. Variabel dalam dataset terdiri atas 10 variabel numerik, 10 variabel kategorik, dan 1 variabel target (y) yang menunjukkan status berlangganan deposito (yes/no).

Distribusi Kelas Target ✨ ✨ ✨



Distribusi kelas target menunjukkan ketidakseimbangan data, dengan 88,73% nasabah tidak berlangganan deposito dan 11,27% nasabah berlangganan. Oleh karena itu, digunakan metode SMOTE untuk menyeimbangkan distribusi kelas pada tahap preprocessing.

Data Preprocessing

1. Remove duplicate

```
df.duplicated().sum()  
  
np.int64(12)  
  
df = df.drop_duplicates()
```

3. One hot Encoding

```
*** Kolom kategorikal nominal: ['job', 'marital', 'education', 'default', 'housing', 'loan', 'con  
Shape setelah One-Hot Encoding: (41176, 54)  
age duration campaign pdays previous emp.var.rate cons.price.idx cons.conf.idx eur  
0 56 261 1 999 0 1.1 93.994 -36.4  
1 57 149 1 999 0 1.1 93.994 -36.4  
2 37 226 1 999 0 1.1 93.994 -36.4  
3 40 151 1 999 0 1.1 93.994 -36.4  
4 56 307 1 999 0 1.1 93.994 -36.4  
5 rows x 54 columns
```

2. Penanganan outlier dengan winsorizing

```
age -> Lower Bound = 26.00, Upper Bound = 58.00  
duration -> Lower Bound = 36.00, Upper Bound = 753.00  
campaign -> Lower Bound = 1.00, Upper Bound = 7.00  
previous -> Lower Bound = 0.00, Upper Bound = 1.00
```

```
Shape setelah Winsorizing: (41176, 21)  
Jumlah baris tidak berubah karena Winsorizing tidak menghapus data.
```

Data Preprocessing

4. Train test split

```
X_train: (32940, 53)  
X_test : (8236, 53)
```

6. SMOTE

```
X_train_scaled: (32940, 53)  
X_test_scaled : (8236, 53)
```

5. Standarisasi

```
Distribusi kelas setelah SMOTE:  
y  
0    29229  
1    29229  
Name: count, dtype: int64  
  
Ukuran X_train: (58458, 53)  
Ukuran X_test : (8236, 53)
```


Pemodelan

1. Logistic regression

```
--- Logistic Regression ---
Accuracy: 0.8647
```

	precision	recall	f1-score	support
0	0.99	0.86	0.92	7308
1	0.45	0.90	0.60	928
accuracy			0.86	8236
macro avg	0.72	0.88	0.76	8236
weighted avg	0.93	0.86	0.88	8236

2. Decision tree

```
--- Decision Tree ---
Accuracy: 0.8820
```

	precision	recall	f1-score	support
0	0.94	0.92	0.93	7308
1	0.48	0.56	0.52	928
accuracy			0.88	8236
macro avg	0.71	0.74	0.72	8236
weighted avg	0.89	0.88	0.89	8236

Pemodelan

3. Random forest

```
--- Random Forest ---
Accuracy: 0.9089
      precision    recall  f1-score   support

     0       0.95      0.95      0.95     7308
     1       0.59      0.62      0.60      928

   accuracy          0.91     8236
  macro avg       0.77      0.78      0.78     8236
 weighted avg     0.91      0.91      0.91     8236
```

4. XGBoost

```
--- XGBoost ---
Accuracy: 0.9145
      precision    recall  f1-score   support

     0       0.95      0.95      0.95     7308
     1       0.62      0.62      0.62      928

   accuracy          0.91     8236
  macro avg       0.79      0.79      0.79     8236
 weighted avg     0.91      0.91      0.91     8236
```


5. Random forest (setelah tuning)

```
--- Random Forest (Tuned) ---
Accuracy: 0.8847
      precision    recall  f1-score   support

     0       0.98      0.89      0.93     7308
     1       0.49      0.87      0.63      928

   accuracy          0.88     8236
  macro avg       0.74      0.88      0.78     8236
 weighted avg     0.93      0.88      0.90     8236
```



Confusion Matrix & ROC-AUC



Berdasarkan confusion matrix, model mampu mengklasifikasikan sebagian besar data dengan benar, ditunjukkan oleh tingginya jumlah True Negative (6957) dan True Positive (575) dibandingkan kesalahan klasifikasi (False Positive = 351 dan False Negative = 353). Selain itu, nilai ROC-AUC sebesar 0,9480 menunjukkan bahwa model memiliki kemampuan yang sangat baik dalam membedakan nasabah yang berlangganan dan tidak berlangganan deposito.

ROC-AUC: 0.9480

Feature Importance



Analisis feature importance menunjukkan bahwa duration merupakan variabel yang paling berpengaruh dalam menentukan keputusan nasabah untuk berlangganan deposito. Hal ini menunjukkan bahwa lamanya interaksi antara pihak bank dan nasabah memiliki peran penting dalam keberhasilan penawaran produk deposito.

Kesimpulan



1. Model machine learning berhasil dibangun untuk mengklasifikasikan keputusan nasabah dalam berlangganan deposito melalui tahapan preprocessing, SMOTE, pemodelan, dan evaluasi model.
2. Berdasarkan hasil pemodelan, XGBoost dipilih sebagai model terbaik dengan akurasi sebesar 91,45%.
3. Hasil analisis feature importance menunjukkan bahwa duration merupakan variabel yang paling berpengaruh terhadap keputusan nasabah untuk berlangganan deposito, sehingga durasi komunikasi menjadi faktor penting dalam keberhasilan kampanye pemasaran bank.

**Terima
Kasih** ✨ ✨ ✨